




Módulo 2 – Machine Learning

Bloque Temático: Estadística


- Introducción a Estadística.
- Estadística Descriptiva.
 - Tablas de Frecuencias.
 - Gráficos.
 - Resúmenes numéricos.



“La disciplina de estadística nos enseña cómo realizar juicios inteligentes y **tomar decisiones informadas entre la presencia de incertidumbre y variación**. Sin incertidumbre y variación, habría poca necesidad de métodos estadísticos o de profesionales en estadística.” Jay E. Devore



Muestreo



Muestreo

30.452.964 $\xrightarrow{A/B}$ $\xrightarrow{Per.}$ $\xrightarrow{Imp.}$

Muestreo no probabilístico



Muestreo por conveniencia



Muestreo deliberado, crítico
o por juicio



Muestreo bola de nieve



Muestreo por cuotas

Muestreo probabilístico

Muestreo aleatorio simple



Muestreo sistemático



Muestreo estratificado



Muestreo por conglomerados



Muestreo: Muestreo Probabilístico

Muestreo	Qué es	Ventaja	Desventaja
 Aleatorio simple	Método por el cual todas las personas de un universo y que estén descritas en un marco muestral tienen las mismas posibilidades de participar.	La generación de números al azar a través de software permite que cada vez sea más rápido.	Es difícil llevarlo a la práctica en el cumplimiento de sus condiciones: mismas oportunidades para todos y que pertenezcan a un marco muestral.
 Estratificado	Consiste en dividir a la población objeto en diferentes subgrupos o estratos de forma que un individuo sólo tenga permanencia en uno de ellos. Si la clasificación es correcta, se espera, por ejemplo, que todas las mujeres de ese grupo actúen muy similar.	Permite estimar con precisión: la muestra, la media, proporciones representativas y un nivel de error predeterminado.	La selección de las variables de estratificación puede ser difícil si un estudio implica un gran número de variables.
 Sistemático	Consistente en seleccionar a un individuo de forma aleatoria entre la población objetivo y, a partir de él, seleccionar para la muestra a cada "n" individuo disponible en el marco muestral.	Es un proceso simple y rápido. Los resultados obtenidos son representativos de la población, de forma similar a los que pudieran obtenerse con el muestreo aleatorio simple.	Existe la posibilidad de que se genere una muestra sesgada sólo cuando el orden en el que se ha generado la selección de participantes tenga algún tipo de periodicidad oculta que coincida con el intervalo seleccionado.
 Conglomerados	Se refiere a la selección de una muestra que reúne todas las variables a estudiar y el grupo seleccionado representa correctamente a toda la población objetivo.	La principal ventaja es su eficiencia operativa; como por ejemplo: evitar traslados a diferentes puntos geográficos, ahorro de tiempo al no depender de los saltos del método probabilístico que marcan la pauta entre una persona y otra.	Uno de los principales riesgos corresponde a que no se tenga la precaución de que los conglomerados sean homogéneos, generando errores.

Muestreo: Muestreo NO Probabilístico

Muestreo	Qué es	Ventaja	Desventaja
 Conveniencia	Consiste en la selección de una muestra de la población por su fácil acceso a ella; es decir, se conjuga la necesidad de la investigación con la disponibilidad del participante.	Bajos costos y facilidad operativa, así como reducción del tiempo empleado.	La muestra, al no ser seleccionada mediante un criterio estadístico, restringe que los resultados obtenidos se consideren como generalidades. No se pueden hacer afirmaciones de rigor estadístico y se desconocerá a qué parte del universo estudiado pertenece esa muestra tomada.
 Cuotas	Se le determina así a la división porcentual de la población total a estudiar a través de los criterios establecidos y es directamente proporcional y equitativa a ella.	Permite acercarse a una representatividad numérica y de criterios de la población de estudio y garantiza que en una serie de variables se reproducirá el comportamiento de ella.	No se puede afirmar el porcentaje de representatividad.
 Bola de nieve	Su importancia radica en que la muestra de estudio recomienda a personas de entre su círculo de interacción. Las recomendaciones son orientadas al perfil que busca el investigador.	Facilita la ubicación de las personas que conforman la muestra y es útil cuando no se tiene acceso a ella fácilmente.	Derivado de que los participantes son consecuencia de la invitación de participantes previos, no se puede garantizar el porcentaje de precisión que la información obtenida otorgue.
 Intencional	La selección de la muestra corresponde a los investigadores, quienes, previo a un estándar de criterios establecidos, eligen a quien cree que los cubre.	Es de fácil acceso, reduce tiempo y esfuerzos para reunir la muestra.	No es considerada como una metodología científica y se puede considerar sesgada por el juicio y selección de quien investiga.
 Consecutivo	La selección realizada también depende de la disponibilidad de la muestra, pero por un periodo extendido.	Brinda la oportunidad de bordar uno o varios temas con la misma muestra y, derivado de la frecuencia, afinar detalles que se consideren valiosos para la obtención de información.	Frecuentemente se corre el riesgo de que no se concluya el periodo de estudio, principalmente porque el participante abandona el estudio.

Muestreo

$$n = \frac{N \cdot Z^2 \cdot p \cdot (1-p)}{(N-1) \cdot e^2 + Z^2 \cdot p \cdot (1-p)}$$

$\hookrightarrow \underbrace{\quad}_{e^2} \cdot p \rightarrow \text{Nivel de Confianza}^2$

$$n = \frac{Z^2 \cdot p \cdot (1-p)}{e^2}$$

>100.000

SurveyMonkey: Facilita la determinación del tamaño de muestra necesario para encuestas ([link](#)).


Netquest: Calcula el tamaño de muestra necesario para encuestas que miden un porcentaje o proporción, considerando el margen de error y el nivel de confianza ([link](#)).

Calcuworld: Ofrece una calculadora en línea para obtener el tamaño de muestra adecuado para la población que deseas investigar ([link](#)).

Calculadora de tamaño muestral: Permite conseguir el tamaño de muestra adecuado para la población que quieres investigar ([link](#)).

QuestionPro: Te permite cuantificar de forma rápida y efectiva el tamaño de muestra para tu investigación ([link](#)).

Variables



Estadística Descriptiva

Objetivo: Resumir, analizar y sacar conclusiones de un conjunto de datos (buscar otra)

- Tablas de Frecuencias.
 - Datos no agrupados.
 - Datos agrupados.
- Gráficos.
- Resúmenes Numéricos.
 - Medidas de Centralidad.
 - Medidas de Dispersión.

Tablas de Frecuencias

Representación de Datos

Frecuencia Absoluta:

$$f_i$$

$$\sum_{i=1}^n f_i = f_1 + f_2 + \cdots + f_n = N$$

Frecuencia Relativa:

$$n_i = \frac{f_i}{N}$$

$$\sum_{i=1}^n n_i = n_1 + n_2 + \cdots + n_n = 1$$

Frecuencia Relativa Acumulada:

$$F_i$$

Frecuencia Absoluta Acumulada:

$$N_i = \frac{F_i}{N}$$

Tablas de Frecuencias

Datos no agrupados

1, 1, 3, 4, 1, 3, 3, 4, 1, 2
2, 2, 2, 2, 1, 1, 4, 4, 4, 3

$N = 20$

Dato	Frecuencia absoluta	Frecuencia absoluta acumulada	Frecuencia relativa	Frecuencia relativa acumulada
x_i	f_i	F_i	n_i	N_i
1				
2				
3				
4				
Total				

f_i

$$\sum_{i=1}^n f_i = f_1 + f_2 + \cdots + f_n = N$$

$n_i = \frac{f_i}{N}$

$$\sum_{i=1}^n n_i = n_1 + n_2 + \cdots + n_n = 1$$

F_i

$$N_i = \frac{F_i}{N}$$

Tablas de Frecuencias

Datos no agrupados

1, 1, 3, 4, 1, 3, 3, 4, 1, 2

2, 2, 2, 2, 1, 1, 4, 4, 4, 3

$N = 20$

Dato	Frecuencia absoluta	Frecuencia absoluta acumulada	Frecuencia relativa	Frecuencia relativa acumulada
x_i	f_i	F_i	n_i	N_i
1	6			
2	5			
3	4			
4	5			
Total	20			

f_i

$n_i = \frac{f_i}{N}$

F_i

$\sum_{i=1}^n f_i = f_1 + f_2 + \dots + f_n = N$

$\sum_{i=1}^n n_i = n_1 + n_2 + \dots + n_n = 1$

$N_i = \frac{F_i}{N}$

Tablas de Frecuencias

Datos no agrupados

1, 1, 3, 4, 1, 3, 3, 4, 1, 2

2, 2, 2, 2, 1, 1, 4, 4, 4, 3

N = 20

Dato	Frecuencia absoluta	Frecuencia absoluta acumulada	Frecuencia relativa	Frecuencia relativa acumulada
x_i	f_i	F_i	n_i	N_i
1	6	6		
2	5	11		
3	4	15		
4	5	20		
Total	20			

f_i

$$\sum_{i=1}^n f_i = f_1 + f_2 + \dots + f_n = N$$

$n_i = \frac{f_i}{N}$

$$\sum_{i=1}^n n_i = n_1 + n_2 + \dots + n_n = 1$$

F_i

$N_i = \frac{F_i}{N}$

Tablas de Frecuencias

Datos no agrupados

1, 1, 3, 4, 1, 3, 3, 4, 1, 2
2, 2, 2, 2, 1, 1, 4, 4, 4, 3

$N = 20$

Dato	Frecuencia absoluta	Frecuencia absoluta acumulada	Frecuencia relativa	Frecuencia relativa acumulada
x_i	f_i	F_i	n_i	N_i
1	6	6	0,30	
2	5	11	0,25	
3	4	15	0,20	
4	5	20	0,25	
Total	20		1	

f_i
$$\sum_{i=1}^n f_i = f_1 + f_2 + \cdots + f_n = N$$

$$n_i = \frac{f_i}{N}$$
$$\sum_{i=1}^n n_i = n_1 + n_2 + \cdots + n_n = 1$$

F_i
$$N_i = \frac{F_i}{N}$$

Tablas de Frecuencias

Datos no agrupados

1, 1, 3, 4, 1, 3, 3, 4, 1, 2
2, 2, 2, 2, 1, 1, 4, 4, 4, 3

$N = 20$

Dato	Frecuencia absoluta	Frecuencia absoluta acumulada	Frecuencia relativa	Frecuencia relativa acumulada
x_i	f_i	F_i	n_i	N_i
1	6	6	0,30	0,30
2	5	11	0,25	0,55
3	4	15	0,20	0,75
4	5	20	0,25	1,00
Total	20		1	

f_i

$$\sum_{i=1}^n f_i = f_1 + f_2 + \dots + f_n = N$$

$n_i = \frac{f_i}{N}$

$$\sum_{i=1}^n n_i = n_1 + n_2 + \dots + n_n = 1$$

F_i

$$N_i = \frac{F_i}{N}$$

Tablas de Frecuencias

Datos agrupados

5,42 6,22 8,42 7,54 6,44 6,76 5,90

6,18 7,16 6,80 7,32 8,12 6,84 7,12

8,21 8,13 7,25 7,34 5,56 8,32 7,45

7,43 6,87 7,10

Intervalos	Frecuencia absoluta fi	Frecuencia absoluta acumulada Fi	Frecuencia relativa ni	Frecuencia relativa acumulada Ni
[5 - 5,5)				
[5,5 - 6)				
[6 - 6,5)				
[6,5 - 7)				
[7 - 7,5)				
[7,5 - 8)				
[8 - 8,5)				
Total				

Límites de clase: Cada intervalo tiene un límite inferior, que pertenece a ese intervalo (cerrado por la izquierda con un corchete) y un límite superior que no pertenece (abierto por la derecha)

Amplitud de clase: La amplitud es la diferencia entre el límite superior e inferior y debe ser **la misma para cada intervalo**

Marca de clase: Es el **punto medio de cada intervalo** y es el valor que se utiliza para calcular otras medidas (realmente para el cálculo de frecuencias no es necesario este valor)

Tablas de Frecuencias

Datos agrupados

5,42 6,22 8,42 7,54 6,44 6,76 5,90

6,18 7,16 6,80 7,32 8,12 6,84 7,12

8,21 8,13 7,25 7,34 5,56 8,32 7,45

7,43 6,87 7,10

Intervalos	Frecuencia absoluta f_i	Frecuencia absoluta acumulada F_i	Frecuencia relativa n_i	Frecuencia relativa acumulada N_i
[5 - 5,5)	1			
[5,5 - 6)	2			
[6 - 6,5)	3			
[6,5 - 7)	4			
[7 - 7,5)	8			
[7,5 - 8)	1			
[8 - 8,5)	5			
Total	24			

Tablas de Frecuencias

Datos agrupados

5,42 6,22 8,42 7,54 6,44 6,76 5,90

6,18 7,16 6,80 7,32 8,12 6,84 7,12

8,21 8,13 7,25 7,34 5,56 8,32 7,45

7,43 6,87 7,10

Intervalos	Frecuencia absoluta fi	Frecuencia absoluta acumulada Fi	Frecuencia relativa ni	Frecuencia relativa acumulada Ni
[5 - 5,5)	1	1		
[5,5 - 6)	2	3		
[6 - 6,5)	3	6		
[6,5 - 7)	4	10		
[7 - 7,5)	8	18		
[7,5 - 8)	1	19		
[8 - 8,5)	5	24		
Total	24			

Rango

$$R = x_{\{max\}} - x_{\{min\}}$$

Regla de Sturges

$$K = 1 + 3,322 \ln(n)$$

Segmentos

$$C = \frac{R}{K}$$

Tablas de Frecuencias

Datos agrupados

5,42 6,22 8,42 7,54 6,44 6,76 5,90

6,18 7,16 6,80 7,32 8,12 6,84 7,12

8,21 8,13 7,25 7,34 5,56 8,32 7,45

7,43 6,87 7,10

Intervalos	Frecuencia absoluta f_i	Frecuencia absoluta acumulada F_i	Frecuencia relativa n_i	Frecuencia relativa acumulada N_i
[5 - 5,5)	1	1	0,04	
[5,5 - 6)	2	3	0,08	
[6 - 6,5)	3	6	0,13	
[6,5 - 7)	4	10	0,17	
[7 - 7,5)	8	18	0,33	
[7,5 - 8)	1	19	0,04	
[8 - 8,5)	5	24	0,21	
Total	24		1,00	

Tablas de Frecuencias

Datos agrupados

5,42 6,22 8,42 7,54 6,44 6,76 5,90

6,18 7,16 6,80 7,32 8,12 6,84 7,12

8,21 8,13 7,25 7,34 5,56 8,32 7,45

7,43 6,87 7,10

Intervalos	Frecuencia absoluta f_i	Frecuencia absoluta acumulada F_i	Frecuencia relativa n_i	Frecuencia relativa acumulada N_i
[5 - 5,5)	1	1	0,04	0,04
[5,5 - 6)	2	3	0,08	0,13
[6 - 6,5)	3	6	0,13	0,25
[6,5 - 7)	4	10	0,17	0,42
[7 - 7,5)	8	18	0,33	0,75
[7,5 - 8)	1	19	0,04	0,79
[8 - 8,5)	5	24	0,21	1,00
Total	24		1,00	




Resúmenes Numéricos: Momentos Estadísticos

Momentos de
Distribución
Estadísticos

Tendencia Central: Media, Mediana, Moda y Fractiles.

Promedio $\bar{x} = \sum \frac{x_i}{n}$


$\bar{M} = 2S \rightarrow \bar{x} : 24 \pm 1$
Parámetro Estimado



Dispersión: Rango, Varianza, Desviación Estandar y Desviación Intercuartil.

$(x_{max} - x_{min})$

$\sigma = \sqrt{s}$



$x_i - \bar{x} = \Delta x_i$

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n} = \frac{\sum \Delta x_i^2}{n}$$

$$\sqrt{s^2} = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n}} = \sigma$$


Asimetría o Sesgo: CA

Curtosis: K


msk

Resúmenes Numéricos: Medidas de Tendencia Central (Media, Mediana, Moda y Fractiles)

Resúmenes Numéricos: Medidas de Dispersión (Rango, Varianza, Desviación Estandar y Desviación Intercuartil)




Resúmenes Numéricos



Asimetría o Sesgo



$$A_s = \frac{3(\bar{x} - M_e)}{S}$$

Coef. Karl Pearson



$$A_s = \frac{Q_1 + Q_3 - 2Q_2}{Q_3 - Q_1}$$

Coef. Yule Bowley




$$CA = \frac{n}{(n-1)(n-2)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{S} \right)^3$$

Coef. Fisher

Resúmenes Numéricos


**Distribución simétrica
o en forma de
campana (Normal)**



Se cumple:

$$\begin{aligned} |X_{\min} - Q_1| &= |X_{\max} - Q_3| \\ |Q_2 - Q_1| &= |Q_2 - Q_3| \\ Q_2 &= \bar{X} \end{aligned}$$


**Distribución asimétrica
negativa (cola hacia
la izquierda)**



Se cumple:

$$\bar{X} < Q_2 = M_e < M_o$$

**Distribución asimétrica
positiva (cola hacia
la derecha)**




Se cumple:

$$\bar{X} > Q_2 = M_e > M_o$$

Donde: $X_{\min}$ → valor mínimo, $X_{\max}$ → valor máximo, Q_1, Q_2, Q_3 → Cuartiles, $\bar{X}$ → media, M_e → mediana, M_o → moda

Curtosis

$$K = \frac{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^4}{\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \right)^2} - 3$$





cole nussbaumer knaflic

storytelling with data

a data
visualization
guide for
business
professionals

WILEY

Realizar los distintos gráficos:

1. Boxplot
2. Gráficos de dispersión
3. Histogramas
4. Gráficos de densidad

Con el dataset: cars_2010_2020.csv

Presentamos 20:40hs

Gráficos

