



Módulo 2 – Machine Learning

Bloque Temático: Estadística Inferencial

- Repaso de conceptos.
- OLS.
- Aplicaciones.






Resúmenes Numéricos: Momentos Estadísticos

Momentos de
Distribución
Estadísticos

Tendencia Central: Media, Mediana, Moda y Fractiles.

Promedio $\bar{x} = \sum \frac{x_i}{n}$

$\bar{M} = 2S \rightarrow \bar{x} : 24 \pm 1$
Parámetro Estimado




Dispersión: Rango, Varianza, Desviación Estandar y Desviación Intercuartil.

$Q_3 - Q_1 = DSC$

$(x_{m2x} - x_{m1})$

$\sigma = \sqrt{s}$



$x_1 - \bar{x} = \Delta x_1$


$$n' = \frac{\sum (x_i - \bar{x})^2}{n} = \frac{\sum \Delta x_i^2}{n}$$

$$\sqrt{V} = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n}} = \sigma$$


Asimetría o Sesgo: CA

Curtosis: K

m
s
k
g




Resúmenes Numéricos



Asimetría o Sesgo



$$A_s = \frac{3(\bar{x} - M_e)}{S}$$

Coef. Karl Pearson



$$A_s = \frac{Q_1 + Q_3 - 2Q_2}{Q_3 - Q_1}$$

Coef. Yule Bowley




$$CA = \frac{n}{(n-1)(n-2)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{S} \right)^3$$

Coef. Fisher

Resúmenes Numéricos


**Distribución simétrica
o en forma de
campana (Normal)**



Se cumple:

$$|X_{\min} - Q_1| = |X_{\max} - Q_3|$$
$$|Q_2 - Q_1| = |Q_2 - Q_3|$$
$$Q_2 = \bar{X}$$


**Distribución asimétrica
negativa (cola hacia
la izquierda)**



Se cumple:

$$\bar{X} < Q_2 = M_e < M_o$$

**Distribución asimétrica
positiva (cola hacia
la derecha)**




Se cumple:

$$\bar{X} > Q_2 = M_e > M_o$$

Donde: $X_{\min}$ → valor mínimo, $X_{\max}$ → valor máximo, Q_1, Q_2, Q_3 → Cuartiles, $\bar{X}$ → media, M_e → mediana, M_o → moda

Curtosis

$$K = \frac{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^4}{\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \right)^2} - 3$$





cole nussbaumer knaflic

storytelling with data

a data
visualization
guide for
business
professionals

WILEY

Realizar los distintos gráficos:


1. Boxplot
2. Gráficos de dispersión
3. Histogramas
4. Gráficos de densidad

Con el dataset: cars_2010_2020.csv



Presentamos 20:40hs

Gráficos


EDA




Covarianza es un valor que indica el grado de variación conjunta de dos variables aleatorias respecto a sus medias. Es el dato básico para determinar si existe una dependencia entre ambas variables y además es el dato necesario para estimar otros parámetros básicos, como el coeficiente de correlación lineal o la recta de regresión.



$$r_{xy} = \frac{S_{XY}}{S_x S_y} = \frac{1}{(n-1)} \sum_{i=1}^n \overbrace{(x_i - \bar{x})}^{\Delta x_i} \overbrace{(y_i - \bar{y})}^{\Delta y_i} = \frac{1}{(n-1)} \left(\sum_{i=1}^{n=10} x_i y_i - n \bar{x} \bar{y} \right) \frac{1}{\sqrt{\sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n}} \cdot \sqrt{\sum_{i=1}^n \frac{(y_i - \bar{y})^2}{n}}}$$



La **correlación** indica la fuerza y la dirección de una relación lineal y la proporcionalidad entre dos variables estadísticas.



$$\frac{\Delta y}{\Delta x} = \text{slope} = a$$

$$\Delta y = a \Delta x \rightarrow$$

$$y = ax + b$$

$$\rho_{xy} = \frac{\sigma_{xy}}{\sigma_x \sigma_y}$$


Población

$$r_{xy} = \frac{S_{xy}}{S_x S_y}$$


Muestra

$$\sigma_x = \sqrt{\sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n}}$$


El coeficiente de correlación es 0.00




El coeficiente de correlación es 0.30




El coeficiente de correlación es 0.50




El coeficiente de correlación es 0.70




El coeficiente de correlación es 0.90




El coeficiente de correlación es 0.95




El coeficiente de correlación es -0.20




El coeficiente de correlación es -0.40




El coeficiente de correlación es -0.60



El coeficiente de correlación es -0.80



El coeficiente de correlación es -0.95



El coeficiente de correlación es -0.99

