







Módulo 2 – Machine Learning

Bloque Temático: Regresiones

- Regresión Lineal Simple.
- Clasificación y Regresión.
- Regresión Logística.





$$y = a \cdot x +$$

c

$$y = a_1 x_1 + a_2 x_2 + a_3 x_3 + \dots + a_n x_n + \underline{c}$$

Predict, Calculate, Extrapolate – GeoGebra

<https://playground.tensorflow.org/>


Regresión Lineal Simple



Modelo de regresión lineal simple


Existen parámetros β_0 , β_1 y σ^2 de tal suerte que con cualquier valor fijo de la variable independiente x , la variable dependiente está relacionada con x por conducto de la **ecuación de modelo**

$$Y = \beta_0 + \beta_1 x + \epsilon \quad (12.1)$$

La cantidad ϵ en la ecuación de modelo es una variable aleatoria, que se supone está normalmente distribuida con $E(\epsilon) = 0$ y $V(\epsilon) = \sigma^2$.







$$f(b_0, b_1) = \sum_{i=1}^n [y_i - (b_0 + b_1x_i)]^2$$

$$b_1 = \hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}$$

$$b_0 = \hat{\beta}_0 = \frac{\sum y_i - \hat{\beta}_1 \sum x_i}{n} = \bar{y} - \hat{\beta}_1 \bar{x}$$

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
rownames											
Mazda RX4	21.0	6	160.0	110	3.90	2.620	16.46	0	1	4	4
Mazda RX4 Wag	21.0	6	160.0	110	3.90	2.875	17.02	0	1	4	4
Datsun 710	22.8	4	108.0	93	3.85	2.320	18.61	1	1	4	1
Hornet 4 Drive	21.4	6	258.0	110	3.08	3.215	19.44	1	0	3	1
Hornet Sportabout	18.7	8	360.0	175	3.15	3.440	17.02	0	0	3	2
Valiant	18.1	6	225.0	105	2.76	3.460	20.22	1	0	3	1
Duster 360	14.3	8	360.0	245	3.21	3.570	15.84	0	0	3	4
Merc 240D	24.4	4	146.7	62	3.69	3.190	20.00	1	0	4	2
Merc 230	22.8	4	140.8	95	3.92	3.150	22.90	1	0	4	2
Merc 280	19.2	6	167.6	123	3.92	3.440	18.30	1	0	4	4
Merc 280C	17.8	6	167.6	123	3.92	3.440	18.90	1	0	4	4
Merc 450SE	16.4	8	275.8	180	3.07	4.070	17.40	0	0	3	3
Merc 450SL	17.2	8	275.8	180	3.07	3.720	17.60	0	0	3	3

OLS Regression Results						
=====						
Dep. Variable:	mpg	R-squared:	0.602			
Model:	OLS	Adj. R-squared:	0.589			
Method:	Least Squares	F-statistic:	45.46			
Date:	Mon, 19 May 2025	Prob (F-statistic):	1.79e-07			
Time:	21:33:39	Log-Likelihood:	-87.619			
No. Observations:	32	AIC:	179.2			
Df Residuals:	30	BIC:	182.2			
Df Model:	1					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	30.0989	1.634	18.421	0.000	26.762	33.436
hp	-0.0682	0.010	-6.742	0.000	-0.089	-0.048
=====						
Omnibus:	3.692	Durbin-Watson:	1.134			
Prob(Omnibus):	0.158	Jarque-Bera (JB):	2.984			
Skew:	0.747	Prob(JB):	0.225			
Kurtosis:	2.935	Cond. No.	386.			
=====						

```

=====
                        OLS Regression Results
=====
Dep. Variable:          mpg      R-squared:                0.602
Model:                  OLS      Adj. R-squared:             0.589
Method:                 Least Squares      F-statistic:           45.46
Date:                   Mon, 19 May 2025    Prob (F-statistic):      1.79e-07
Time:                   21:33:39      Log-Likelihood:         -87.619
No. Observations:       32      AIC:                    179.2
Df Residuals:           30      BIC:                    182.2
Df Model:                1
Covariance Type:        nonrobust
=====

```

	coef	std err	t	P> t	[0.025	0.975]
const	30.0989	1.634	18.421	0.000	26.762	33.436
hp	-0.0682	0.010	-6.742	0.000	-0.089	-0.048

```

=====
Omnibus:                3.692      Durbin-Watson:           1.134
Prob(Omnibus):           0.158      Jarque-Bera (JB):        2.984
Skew:                    0.747      Prob(JB):                0.225
Kurtosis:                2.935      Cond. No.:               386.
=====

```

Tiene en cuenta el nro
De variables y tamaño
de muestra.

```

=====
                        OLS Regression Results
=====
Dep. Variable:          mpg      R-squared:                0.602
Model:                  OLS      Adj. R-squared:           0.589
Method:                 Least Squares      F-statistic:           45.46
Date:                   Mon, 19 May 2025    Prob (F-statistic):     1.79e-07
Time:                   21:33:39      Log-Likelihood:        -87.619
No. Observations:       32      AIC:                   179.2
Df Residuals:           30      BIC:                   182.2
Df Model:               1
Covariance Type:        nonrobust
=====

```

	coef	std err	t	P> t	[0.025	0.975]
const	30.0989	1.634	18.421	0.000	26.762	33.436
hp	-0.0682	0.010	-6.742	0.000	-0.089	-0.048

```

=====
Omnibus:                3.692      Durbin-Watson:           1.134
Prob(Omnibus):           0.158      Jarque-Bera (JB):        2.984
Skew:                    0.747      Prob(JB):                0.225
Kurtosis:                2.935      Cond. No.:               386.
=====

```

Tiene en cuenta el nro
De variables y tamaño
de muestra.

Significancia estadística
Del modelo.

OLS Regression Results						
=====						
Dep. Variable:	mpg	R-squared:	0.602			
Model:	OLS	Adj. R-squared:	0.589			
Method:	Least Squares	F-statistic:	45.46			
Date:	Mon, 19 May 2025	Prob (F-statistic):	1.79e-07			
Time:	21:33:39	Log-Likelihood:	-87.619			
No. Observations:	32	AIC:	179.2			
Df Residuals:	30	BIC:	182.2			
Df Model:	1					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	30.0989	1.634	18.421	0.000	26.762	33.436
hp	-0.0682	0.010	-6.742	0.000	-0.089	-0.048
=====						
Omnibus:	3.692	Durbin-Watson:	1.134			
Prob(Omnibus):	0.158	Jarque-Bera (JB):	2.984			
Skew:	0.747	Prob(JB):	0.225			
Kurtosis:	2.935	Cond. No.	386.			
=====						

Tiene en cuenta el nro
De variables y tamaño
de muestra.

Significancia estadística
Del modelo.

Un valor de Log-likelihood
más alto (menos negativo)
indica que el modelo se
ajusta mejor a los datos.

OLS Regression Results						
=====						
Dep. Variable:	mpg	R-squared:		0.602		
Model:	OLS	Adj. R-squared:		0.589		
Method:	Least Squares	F-statistic:		45.46		
Date:	Mon, 19 May 2025	Prob (F-statistic):		1.79e-07		
Time:	21:33:39	Log-Likelihood:		-87.619		
No. Observations:	32	AIC:		179.2		
Df Residuals:	30	BIC:		182.2		
Df Model:	1					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	30.0989	1.634	18.421	0.000	26.762	33.436
hp	-0.0682	0.010	-6.742	0.000	-0.089	-0.048
=====						
Omnibus:	3.692	Durbin-Watson:		1.134		
Prob(Omnibus):	0.158	Jarque-Bera (JB):		2.984		
Skew:	0.747	Prob(JB):		0.225		
Kurtosis:	2.935	Cond. No.		386.		
=====						

Tiene en cuenta el nro
De variables y tamaño
de muestra.

Significancia estadística
Del modelo.

Un valor de Log-likelihood
más alto (menos negativo)
indica que el modelo se
ajusta mejor a los datos.

Penalizan modelos con
más parámetros para
evitar el sobreajuste.
Valor bajo indica
equilibrio entre ajuste y
complejidad.

Grados de Libertad

OLS Regression Results						
=====						
Dep. Variable:	mpg	R-squared:	0.602			
Model:	OLS	Adj. R-squared:	0.589			
Method:	Least Squares	F-statistic:	45.46			
Date:	Mon, 19 May 2025	Prob (F-statistic):	1.79e-07			
Time:	21:33:39	Log-Likelihood:	-87.619			
No. Observations:	32	AIC:	179.2			
Df Residuals:	30	BIC:	182.2			
Df Model:	1					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	30.0989	1.634	18.421	0.000	26.762	33.436
hp	-0.0682	0.010	-6.742	0.000	-0.089	-0.048
=====						
Omnibus:	3.692	Durbin-Watson:		1.134		
Prob(Omnibus):	0.158	Jarque-Bera (JB):		2.984		
Skew:	0.747	Prob(JB):		0.225		
Kurtosis:	2.935	Cond. No.		386.		
=====						

Tiene en cuenta el nro De variables y tamaño de muestra.

Significancia estadística Del modelo.

Un valor de Log-likelihood **más alto (menos negativo)** indica que el modelo se ajusta mejor a los datos.

Penalizan modelos con más parámetros para evitar el sobreajuste. Valor bajo indica equilibrio entre ajuste y complejidad.

Grados de Libertad

"Omnibus" en regresión lineal es solo una forma de referirse a la **prueba F de significancia global del modelo**

OLS Regression Results

Dep. Variable:

mpg

R-squared:

0.602

Model:

OLS

Adj. R-squared:

0.589

Method:

Least Squares

F-statistic:

45.46

Date:

Mon, 19 May 2025

Prob (F-statistic):

1.79e-07

Time:

21:33:39

Log-Likelihood:

-87.619

No. Observations:

32

AIC:

179.2

Df Residuals:

30

BIC:

182.2

Df Model:

1

Covariance Type:

nonrobust

coef

std err

t

P>|t|

[0.025

0.975]

const

30.0989

1.634

18.421

0.000

26.762

33.436

hp

-0.0682

0.010

-6.742

0.000

-0.089

-0.048

Omnibus:

3.692

Durbin-Watson:

1.134

Prob(Omnibus):

0.158

Jarque-Bera (JB):

2.984

Skew:

0.747

Prob(JB):

0.225

Kurtosis:

2.935

Cond. No.

386.

Tiene en cuenta el nro De variables y tamaño de muestra.

Significancia estadística Del modelo.

Un valor de Log-likelihood **más alto (menos negativo)** indica que el modelo se ajusta mejor a los datos.

Penalizan modelos con más parámetros para evitar el sobreajuste. Valor bajo indica equilibrio entre ajuste y complejidad.

Grados de Libertad

"Omnibus" en regresión lineal es solo una forma de referirse a la **prueba F de significancia global del modelo**

autocorrelación ocurre cuando los errores (residuos) de las observaciones en un modelo no son independientes entre sí

OLS Regression Results

Dep. Variable:

mpg

R-squared:

0.602

Model:

OLS

Adj. R-squared:

0.589

Method:

Least Squares

F-statistic:

45.46

Date:

Mon, 19 May 2025

Prob (F-statistic):

1.79e-07

Time:

21:33:39

Log-Likelihood:

-87.619

No. Observations:

32

AIC:

179.2

Df Residuals:

30

BIC:

182.2

Df Model:

1

Covariance Type:

nonrobust

coef

std err

t

P>|t|

[0.025

0.975]

const

30.0989

1.634

18.421

0.000

26.762

33.436

hp

-0.0682

0.010

-6.742

0.000

-0.089

-0.048

Omnibus:

3.692

Durbin-Watson:

1.134

Prob(Omnibus):

0.158

Jarque-Bera (JB):

2.984

Skew:

0.747

Prob(JB):

0.225

Kurtosis:

2.935

Cond. No.

386.

Tiene en cuenta el nro De variables y tamaño de muestra.

Significancia estadística Del modelo.

Un valor de Log-likelihood **más alto (menos negativo)** indica que el modelo se ajusta mejor a los datos.

Penalizan modelos con más parámetros para evitar el sobreajuste. Valor bajo indica equilibrio entre ajuste y complejidad.

Grados de Libertad

"Omnibus" en regresión lineal es solo una forma de referirse a la **prueba F de significancia global del modelo**

autocorrelación ocurre cuando los errores (residuos) de las observaciones en un modelo no son independientes entre sí

Jarque-Bera es una herramienta clave para diagnosticar si tus residuos de regresión cumplen con el supuesto de normalidad

Prob. Y Est. Para Ing. Y Ciencia – Jay L. Devore

OLS Regression Results

Dep. Variable:

mpg

R-squared:

0.602

Model:

OLS

Adj. R-squared:

0.589

Method:

Least Squares

F-statistic:

45.46

Date:

Mon, 19 May 2025

Prob (F-statistic):

1.79e-07

Time:

21:33:39

Log-Likelihood:

-87.619

No. Observations:

32

AIC:

179.2

Df Residuals:

30

BIC:

182.2

Df Model:

1

Covariance Type:

nonrobust

coef

std err

t

P>|t|

[0.025

0.975]

const

30.0989

1.634

18.421

0.000

26.762

33.436

hp

-0.0682

0.010

-6.742

0.000

-0.089

-0.048

Omnibus:

3.692

Durbin-Watson:

1.134

Prob(Omnibus):

0.158

Jarque-Bera (JB):

2.984

Skew:

0.747

Prob(JB):

0.225

Kurtosis:

2.935

Cond. No.

386.

Tiene en cuenta el nro De variables y tamaño de muestra.

Significancia estadística Del modelo.

Un valor de Log-likelihood **más alto (menos negativo)** indica que el modelo se ajusta mejor a los datos.

Penalizan modelos con más parámetros para evitar el sobreajuste. Valor bajo indica equilibrio entre ajuste y complejidad.

Grados de Libertad

"Omnibus" en regresión lineal es solo una forma de referirse a la **prueba F de significancia global del modelo**

autocorrelación ocurre cuando los errores (residuos) de las observaciones en un modelo no son independientes entre sí

Jarque-Bera es una herramienta clave para diagnosticar si tus residuos de regresión cumplen con el supuesto de normalidad

Prob. Y Est. Para Ing. Y Ciencia – Jay L. Devore

OLS Regression Results

Dep. Variable:

mpg

R-squared:

0.602

Model:

OLS

Adj. R-squared:

0.589

Method:

Least Squares

F-statistic:

45.46

Date:

Mon, 19 May 2025

Prob (F-statistic):

1.79e-07

Time:

21:33:39

Log-Likelihood:

-87.619

No. Observations:

32

AIC:

179.2

Df Residuals:

30

BIC:

182.2

Df Model:

1

Covariance Type:

nonrobust

coef

std err

t

P>|t|

[0.025

0.975]

const

30.0989

1.634

18.421

0.000

26.762

33.436

hp

-0.0682

0.010

-6.742

0.000

-0.089

-0.048

Omnibus:

3.692

Durbin-Watson:

1.134

Prob(Omnibus):

0.158

Jarque-Bera (JB):

2.984

Skew:

0.747

Prob(JB):

0.225

Kurtosis:

2.935

Cond. No.

386.

Tiene en cuenta el nro De variables y tamaño de muestra.

Significancia estadística Del modelo.

Un valor de Log-likelihood **más alto (menos negativo)** indica que el modelo se ajusta mejor a los datos.


Penalizan modelos con más parámetros para evitar el sobreajuste. Valor bajo indica equilibrio entre ajuste y complejidad.

Condición Numérica (evalúa multicolinealidad)

Regresión Logística

Clasificación


BODY MASS INDEX (kg/m²)



Regresión Logística

Clasificación

Logit



$$f(x) = \frac{1}{1 + e^{-bx+c}}$$

h: 0 → 1
a? c?

→ Linear

$$f(x, z) = \frac{1}{1 + e^{-(ax+bz+c)}}$$

Reg. Lineal → Prob. Reg.



Reg. Logist → Prob. Chas

$$\begin{aligned} \text{si } y \geq 0,5 &\Rightarrow f(y) = 1 \\ y < 0,5 &\Rightarrow f(y) = 0 \end{aligned}$$

Regresión Logística

Clasificación

- Es uno de los modelos más utilizados en Machine Learning.
- Función sigmoid o función logística:



↓ A Realidad A

Modelo

	1	0
1	TP 72	FP 14
0	FN 28	TN 40

Matriz de Confusión

TRAIN → TEST

h2x P, R

$$F1-Score = \frac{2 \cdot P \cdot R}{P + R}$$

MCC ✓

Predict

Real

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$Accuracy = \frac{72 + 40}{28 + 14 + 72 + 40} = 0,73$$

$$Precision = \frac{72}{72 + 14} =$$

Métricas del modelo:

Accuracy: 0.73

Precision: 0.59

Recall: 0.74

F1-Score: 0.66

Matriz de Confusión:

[[72 28]

[14 40]]

Modelo 1

Real

0 $TN_{(0,0)}^{72}$ $FP_{(0,1)}^{28}$

1 $FN_{(1,0)}^{14}$ $TP_{(1,1)}^{40}$

$$P = \frac{TP}{TP + FP} = \frac{40}{40 + 28} \approx 0,59$$

$$R = \frac{TP}{TP + FN} = \frac{40}{40 + 14} = 0,74$$



$$Acc = \frac{72 + 40}{72 + 14 + 28 + 40} = 0,73$$

Esc.

Max $P_y R$

Mejor P sin poder
40% Rec

Mejor R sin poder
40% P




Regresión Logística

Clasificación

- Es uno de los modelos más utilizados en Machine Learning.
- Función sigmoid o función logística.
- Modelo de regresión logística.

$$f_{w,b}(x) = \frac{1}{1 + e^{-(w+bx)}}$$



Regresión Logística

Clasificación

- Es uno de los modelos más utilizados en Machine Learning.
- Función sigmoid o función logística.
- Modelo de regresión logística.

$$f_{w,b}(x) = \frac{1}{1 + e^{-(w+bx)}}$$

¿Cómo se ven con los datos?

Regresión Logística

Clasificación

¿Cómo se encontrar los parámetros w, b ?

- Podemos hacer algo parecido a la OLS.
 - Encontrar una función de pérdida (cuadrados del error).
 - Calcular la función de costo (o ECM).
 - Encontrar los valores mínimos para esa función.
- Veamos las ecuaciones de regresión logística:

$$f_{w,b}(x) = \frac{1}{1 + e^{-(w+bx)}}$$

Función de pérdida:

$$L(w, b) = -y \log(f_{w,b}(x)) - (1 - y) \log(1 - f_{w,b}(x))$$

Función de costo:

$$J(w, b) = \frac{1}{m} \sum_{i=1}^m L(w, b)$$

Regresión Logística

Clasificación

¿Cómo se encontrar los parámetros w, b ?

$$f_{w,b}(x) = \frac{1}{1 + e^{-(w+bx)}}$$

Función de pérdida:

$$L(w, b) = -y \log(f_{w,b}(x)) - (1 - y) \log(1 - f_{w,b}(x))$$

Función de costo:

$$J(w, b) = \frac{1}{m} \sum_{i=1}^m L(w, b)$$

Debemos encontrar w, b que minimice $J(w, b)$:

Aplicamos gradiente:

$$\frac{\partial}{\partial w} J(w, b) = \frac{1}{m} \sum_{i=1}^m (f_{w,b}(x_i) - y_i) x_i$$

$$\frac{\partial}{\partial b} J(w, b) = \frac{1}{m} \sum_{i=1}^m (f_{w,b}(x_i) - y_i)$$